02.03.00 Компьютерные и информационные науки

02.03.01 Математика и компьютерные науки 02.03.02 Фундаментальная информатика и информационные технологии

Основы машинного обучения и нейронные сети

Лекции д.ф.-м.н., проф. Гайдамака Юлия Васильевна **Семинары**

к.ф.-м.н. Бобрикова Екатерина Васильевна (НКАбд-02,03-22) асс. Гриценко Николай Юрьевич (НКАбд-04,05-22) асс. Голос Елизавета Сергеевна (НКАбд-01-22)

кафедра теории вероятностей и кибербезопасности (ТВиК), комн. 224, ygaidamaka@mail.ru консультации вторник 14:00 - 14:50 по предварительной договоренности

Описание дисциплины

- знакомство с научной областью искусственного интеллекта (ИИ, *англ.* artificial intelligence AI)
- определение основных понятий и задач машинного обучения (MO, *англ.* machine learning ML)
- исследование принципов обучения алгоритмов
- освоение методов машинного обучения на примерах из жизни и бизнеса

Цель дисциплины

- изучение постановок задач, типов данных и способов работы с ними
- знакомство с классическими моделями машинного обучения (метрические, линейные, решающие деревья, композиции), методами их обучения
- освоение подходов к измерению качества прогнозирования методами машинного обучения
- закрепление полученных навыков при решении практических задач методами машинного обучения

Организационно-методическое построение дисциплины

Лекции 18 часов (1 ак. час / нед.); практические занятия 36 часов (2 ак. часа / нед.); самостоятельная работа 54 часа (3 ак. часа / нед.)

Страница дисциплины ОМОиНС на портале ТУИС РУДН:

https://esystem.rudn.ru/course/view.php?id=21203 - для 02.03.01, 02.03.02

Порядок начисления баллов

Вид задания	Баллы
1. Посещаемость, активность	10
2. Работа на семинарах, домашние задания	50
3. Промежуточный контроль	20
4. Итоговый контроль (экзамен)	20
ИТОГО	100

Что нам пригодится?

Математический анализ:

- Производные
- Частные производные
- Градиент

Линейная алгебра:

- Векторы и матрицы
- Нормы, метрики, скалярное произведение
- Умножение матриц
- Обращение матриц
- Собственные числа и собственные векторы

Теория вероятностей и математическая статистика (можно и обойтись, но если не лень разбираться):

- Основные дискретные и непрерывные распределения
- Математическое ожидание, дисперсия, моменты
- Ковариация и корреляция

Программирование на Python

Литература

- 1. *Бобрикова Е.В., Гайдамака Ю.В., Самуйлов К.Е.* Основы машинного обучения и нейронные сети: учебное пособие Москва: РУДН, 2024.
- 2. Воронцов К. В. Математические методы обучения по прецедентам. Курс лекций. [Электронный ресурс] / Режим доступа: http://www.machinelearning.ru/wiki/images/6/6d/voron-ml-1.pdf, свободный (дата обращения 01.09.2023)
- 3. Соколов Е. А. Материалы курса «Основы машинного обучения», ВШЭ, майнор ИАД (доп. профиль «Интеллектуальный анализ данных). [Электронный ресурс] / Режим доступа: <a href="http://wiki.cs.hse.ru/%D0%9E%D1%81%D0%BD%D0%BE%D0%B2%D1%8B_%D0%BC%D0%B0%D1%88%D0%B8%D0%BD%D0%BE%D0%BE%D0%BE%D0%BE%D0%B1%D1%83%D1%87%D0%B5%D0%B0%D0%B8%D1%8F, свободный (дата обращения 01.09.2023)
- A Visual Introduction to Machine Learning
 [Электронный ресурс] / Режим доступа: http://www.r2d3.us/visual-intro-to-machine-learning-part-1/, свободный (дата обращения 01.09.2023)

Положение о культуре поведения студентов в учебном процессе (1)

- 2.1.Запрещается входить в аудиторию после начала занятия преподавателем.
- 2.2. Запрещается находиться в аудитории, в любом помещении, в том числе в столовых и кафе в верхней одежде.
- 2.3. При входе преподавателя в аудиторию в начале занятий все студенты встают, приветствуя его.
- 2.4. Запрещается во время занятий прерывание преподавателя, общение между студентами, хождение по аудитории, выход из аудитории без разрешения на то преподавателя. При необходимости поднятием руки студент после полученного разрешения обращается к преподавателю с вопросом или просьбой.
- 2.5. Запрещается в учебных аудиториях употреблять пищу и напитки, пользоваться жевательной резинкой. Необходимо строго соблюдать чистоту и порядок в помещениях и зданиях, не портить имущество Университета, не оставлять надписей на столах и стульях.

Положение о культуре поведения студентов в учебном процессе (2)

- 2.6. Мобильные телефоны и другие электронные средства передачи информации во время занятий должны быть выключены. Пользоваться персональными компьютерами и т.п. можно только с разрешения преподавателя.
- 2.7.Студенты обязаны быть предупредительными и тактичными, уступать дорогу преподавателям и друг другу, не препятствовать входу в здание, проходу по коридорам и холлам здания, не разговаривать громко в коридорах и холлах, в том числе по мобильному телефону.
- 2.8. Студенты обязаны не допускать поведения, оскорбляющего свое и чужое человеческое достоинство, в том числе вульгарность, грубость, сквернословие, хамство.
- 2.9. Студенты на занятиях должны быть внимательными, активными при обсуждении учебных тем, строго следовать указаниям преподавателя. В компьютерных классах допускается работа только с программами указанными преподавателем. На лабораторных и других практических занятиях студенты обязаны строго соблюдать правила безопасности.
- 2.10. Студенты обязаны выглядеть и одеваться опрятно, отдавая предпочтение деловому стилю одежды.

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (1)

Государственное образовательное учреждение высшего профессионального образования

«РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ» (РУДН) ПРИКАЗ РЕКТОРА

2 4 RHB 2011 2005

Москва

Nº 27

Содержание: О Порядке применения дисциплинарных взысканий при нарушениях ак адемических норм в написании письменных учебных работ и при различных формах контроля знаний учащихся

ПРИКАЗЫВАЮ:

1. Утвердить Положение о Порядке применения дисциплинарных взысканий при нарушениях академических норм в написании письменных учебных работ и при различных формах контроля знаний обучающихся (прилагается).

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (2)

ПОРЯДОК ПРИМЕНЕНИЯ ДИСЦИПЛИНАРНЫХ ВЗЫСКАНИЙ ПРИ НАРУШЕНИЯХ АКАДЕМИЧЕСКИХ НОРМ В НАПИСАНИИ ПИСЬ-МЕННЫХ УЧЕБНЫХ РАБОТ И ПРИ РАЗЛИЧНЫХ ФОРМАХ КОНТРОЛЯ ЗНАНИЙ СТУДЕНТОВ В РУДН

1. ОБЩИЕ ПОЛОЖЕНИЯ

- 1.1. Порядок применения дисциплинарных взысканий при нарушениях академических норм в написании письменных учебных работ и при различных формах контроля знаний учащихся (далее Порядок) вводится в целях повышения качества организации учебного процесса, уровня дисциплины обучающихся и стимулирования добросовестной конкуренции в РУДН. Он устанавливает регламент действий преподавателей и администрации университета при обнаружении соответствующих нарушений. Порядок является локальным нормативным актом РУДН и выступает приложением к Правилам внутреннего распорядка Российского университета дружбы народов.
- 1.2. К письменным учебным работам (далее письменные работы) относятся все письменные работы, выполняемые обучающимися в ходе промежуточного и итогового рубежного контроля знаний в соответствии с программой учебной дисциплины, а также в ходе государственных итоговых испытаний. Они включают домашние задания, рефераты, эссе, контрольные работы, письменные работы, выполняемые на экзаменах и зачетах, курсовые и выпускные квалификационные работы, отчеты по практикам. Все письменные работы должны выполняться обучающимися самостоятельно.

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (3)

расоты должны выполняться обучающимися самостоятельно.

- 1.3. К нарушениям академических норм, регламентируемых данным Порядком, относятся:
 - списывание письменных работ,
 - двойная сдача письменных работ,
 - плагиат в письменных работах,
 - подлоги при выполнении письменных работ,
 - фабрикация данных и результатов работы,
 - неявка обучающегося на компьютерное тестирование при проверке остаточных знаний (контрольных ректората),
 - не прохождение обучающимися Интернет-тестирования,
 - неявка обучающегося на тестовую часть государственного экзамена.
- 1.3.1. Списывание определяется как использование любых не разрешенных преподавателем письменных (печатных или рукописных) источников (в том числе, с использованием электронных средств) при прохождении аудиторного рубежного контроля знаний.
- 1.3.2. Двойная сдача определяется как представление одного и того же текста в качестве разных письменных работ для прохождения рубежного контроля знаний. Двойной сдачей не считается использование с согласия преподавателя ранее подготовленного текста как части более объемной работы.

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (4)

1.3.3. Плагиат определяется как использование в письменной работе чужого текста, опубликованного в бумажном или электронном виде, без полной ссылки на источник

2

или со ссылками, но когда объем и характер заимствований ставят под сомнение сам остоятельность выполненной работы или одного из ее основных разделов. Плагиат мож ет осуществляться в двух видах:

- дословное изложение чужого текста,
- парафраза изложение чужого текста с заменой слов и выражений без изменения содержания заимствованного текста. В данном случае факт плагиа та определяется преподавателем, который обязан при необходимости его доказать.

¹ Примечание: Термин «плагиат» используется только для определения одного из видов нарушения правил цитирования, за которые применяется дисциплинарное наказание согласно настоящему Порядку. Во-

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (5)

- 1.3.4. Подлог определяется как сдача письменной работы, выполненной другим лицом, в качестве собственной работы в целях прохождения рубежного контроля знаний или сознательное предоставление собственной работы другому лицу в целях прохождения им рубежного контроля знаний. Если текст использован без разрешения автора, последний не может квалифицироваться как участник подлога.
- 1.3.5. Фабрикация данных и результатов работы определяется как формирование фиктивных данных или намеренное искажение информации об источниках данных и полученных результатах в целях прохождения рубежного контроля знаний.

2. ПРИМЕНЕНИЕ ДИСЦИПЛИНАРНЫХ ВЗЫСКАНИЙ ПРИ НАРУШЕНИИ АКАДЕМИЧЕСКИХ НОРМА В НАПИСАНИИ ПИСЬМЕННЫХ РАБОТ

2.1. При обнаружении любого из указанных выше нарушений академических норм, характер которых ставит под сомнение самостоятельность выполнения письменной работы или одного из ее основных разделов, преподаватель обязан поставить обучающемуся оценку «неудовлетворительно» («F» по системе оценивания ECTS) и сообщить данном факте в деканат факультета (учебного института). Данная работа считается не выполненной. Вариант работы, содержащий нарушения, хранится на кафедре, обеспечивающей данную дисциплину, до завершения официального срока пересдач по данной дисциплине.

о порядке применения дисциплинарных взысканий при нарушении академических норм в написании письменных работ (6)

- 2.2. При обнаружении списывания преподаватель имеет право поставить оценку «неудовлетворительно» (или «F») обучающемуся, предоставившему свой текст для списывания.
- 2.3. При повторном обнаружении списывания преподаватель обязан, помимо проставления неудовлетворительной оценки, в течение трех рабочих дней представить служебную записку с просьбой о применении взыскания на имя декана факультета (директора учебного института)с приложением копии письменной работы (или ее фрагмента), указанием объема списанного текста и его источника.
- Декан факультета (директор учебного института) в отношении обучающегося, уличенного в повторном списывании, может избрать следующие виды дисциплинарных наказаний:
 - замечание,
 - выговор.
- 2.5. При обнаружении плагиата, объем и характер которого ставят под сомнение самостоятельность выполнения письменной работы или одного из ее основных разделов; при повторном обнаружении плагиата; а также при обнаружении двойной сдачи письменной работы преподаватель обязан, помимо проставления неудовлетворительной оценки, в течение трех рабочих дней представить служебную записку с просьбой о применении взыскания на имя декана факультета (директора учебного института) с приложением копии письменной работы (или ее фрагмента), указанием объема заимствованного текста и его источника.



Соколов Е.А. доц., руководитель департамента больших данных и информационного поиска ВШЭ

Материалы курса «Основы машинного обучения», ВШЭ, майнор ИАД (доп. профиль «Интеллектуальный анализ данных)



Воронцов К.В. д.ф.-м.н., проф., ВМиК МГУ, МФТИ, ВЦ РАН им. Дородницына, Яндекс, ВШЭ

Искусственный интеллект

Искусственный интеллект — комплекс технологических решений, позволяющий имитировать когнитивные функции человека и получать при выполнении конкретных задач результаты, сопоставимые, как минимум, с результатами интеллектуальной деятельности человека.

https://medium.com/@eytanmessika/mapping-the-world-artificial-intelligence-landscapes-223f752efa4

ИИ — свойство искусственных интеллектуальных систем выполнять творческие функции, которые традиционно считаются прерогативой человека

Джон Маккарти на семинаре в Дартмутском университете, 1956 год

ИИ — наука и технология создания интеллектуальных машин, особенно интеллектуальных компьютерных программ.

Направления ИИ

- компьютерное зрение
- обработка естественного языка
- распознавание и синтез речи
- интеллектуальные системы поддержки принятия решений
- перспективные методы ИИ

ИИ и промышленные революции



Andreoni и Anzolin (2019), https://www.unido.org/sites/default/files/files/2019-11/UNIDO_IDR2020-Russian_overview.pdf

Искусственный интеллект



McKinsey Technology Trends Outlook 2022 (or 24.08.22)

Потенциал развития ИИ



McKinsey Technology Trends Outlook 2022 (or 24.08.22)

Что может и что не может ИИ 2023?

По большому числу бенчмарков ИИ уже превосходит человека ИИ > Человек ИИ ≈ Человек ИИ < <mark>Человек</mark> лучше любого эксперта как взрослый человек АІ не способен определяет решает общие тесты на к сознательному проявлению дипфейки понимание воли языка 99% > 66% 0 < 100% 90%≈90% на уровне ребенка лучше среднего взрослого на основе утверждений классифицирует объясняет свои на уровне взрослого изображения делает выводы ответы 98% > 95% 72% < 85% 92% ≈ 92% * на основе тестов ImageNET, SuperGLUE, VQA Challenge, FACEFORENSICS++, Stanford QA Dataset, aNLI

Сергей Андреев. Sber Al. Лекция «Digital Summer 2023: Al тренды».

Машинное обучение (1/2)

Машинное обучение – это наука, изучающая способы извлечения закономерностей из ограниченного количества примеров.

Mohri M., Rostamizadeh A., Talwalkar A. Foundations of Machine Learning. MIT Press, 2012. 412 p.

Машинное обучение – вычислительные методы, использующие опыт для повышения производительности или составления точных прогнозов.

Рашка С. Python и Машинное Обучение. ДМК-Пресс, 2017. 418 с.

Машинное обучение (2/2)

Машинное обучение – одно из направлений применения искусственного интеллекта

Машинное обучение:

процесс автоматического построения некоторого алгоритма решения задачи на основе данных.

Обучение:

из множества доступных алгоритмов выбрать такой *алгоритм* решения задачи, который минимизирует ошибку прогнозирования.

Как перевести часы в минуты?

x — часы , $x \in \mathbb{N} \cup \{0\}$

Как перевести часы в минуты?

$$x$$
 — часы , $x \in \mathbb{N} \cup \{0\}$

f(x) = 60x — преобразование часов в минуты, функция

Как перевести часы в минуты?

$$x$$
 — часы , $x \in \mathbb{N} \cup \{0\}$

f(x) = 60x — преобразование часов в минуты, функция

Чему равно ускорение тела массы m, приобретаемое по воздействием приложенной к нему силы F?

Как перевести часы в минуты?

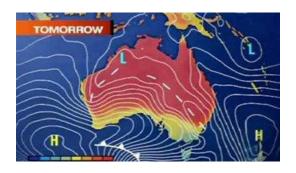
$$x$$
 — часы , $x \in \mathbb{N} \cup \{0\}$

f(x) = 60x — преобразование часов в минуты, функция

Чему равно ускорение тела массы m, приобретаемое по воздействием приложенной к нему силы F?

Второй закон Ньютона: a = F/m

Как предсказать погоду?



Как предсказать погоду?



Уравнения Навье-Стокса.

Как предсказать погоду?



$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + w \frac{\partial u}{\partial z} = -\frac{\partial P}{\partial x} + Re \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right),$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + w \frac{\partial v}{\partial z} = -\frac{\partial P}{\partial y} + Re \left(\frac{\partial^2 v}{\partial x^2} + \frac{\partial^2 v}{\partial y^2} + \frac{\partial^2 v}{\partial z^2} \right),$$

$$\frac{\partial w}{\partial t} + u \frac{\partial w}{\partial x} + v \frac{\partial w}{\partial y} + w \frac{\partial w}{\partial z} = -\frac{\partial P}{\partial z} + Re \left(\frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} + \frac{\partial^2 w}{\partial z^2} \right),$$

$$\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} + \frac{\partial w}{\partial z} = 0.$$

Уравнения Навье-Стокса.

Как предсказать погоду?



Уравнения Навье-Стокса.

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + w \frac{\partial u}{\partial z} = -\frac{\partial P}{\partial x} + Re \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right),$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + w \frac{\partial v}{\partial z} = -\frac{\partial P}{\partial y} + Re \left(\frac{\partial^2 v}{\partial x^2} + \frac{\partial^2 v}{\partial y^2} + \frac{\partial^2 v}{\partial z^2} \right),$$

$$\frac{\partial w}{\partial t} + u \frac{\partial w}{\partial x} + v \frac{\partial w}{\partial y} + w \frac{\partial w}{\partial z} = -\frac{\partial P}{\partial z} + Re \left(\frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} + \frac{\partial^2 w}{\partial z^2} \right),$$

$$\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} + \frac{\partial w}{\partial z} = 0.$$

Нет аналитического решения. Приемлемая точность численного решения - только при расчётной сетке, ячейки которой меньше самого мелкого вихря.

Уравнения Навье-Стокса (1/2)

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + w \frac{\partial u}{\partial z} = -\frac{\partial P}{\partial x} + Re \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right),$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + w \frac{\partial v}{\partial z} = -\frac{\partial P}{\partial y} + Re \left(\frac{\partial^2 v}{\partial x^2} + \frac{\partial^2 v}{\partial y^2} + \frac{\partial^2 v}{\partial z^2} \right),$$

$$\frac{\partial w}{\partial t} + u \frac{\partial w}{\partial x} + v \frac{\partial w}{\partial y} + w \frac{\partial w}{\partial z} = -\frac{\partial P}{\partial z} + Re \left(\frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} + \frac{\partial^2 w}{\partial z^2} \right),$$

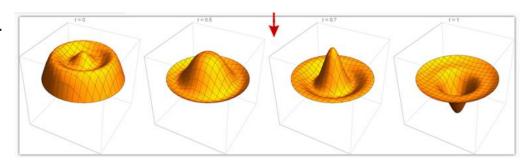
$$\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} + \frac{\partial w}{\partial z} = 0.$$

Уравнения Навье-Стокса (2/2)

Система дифференциальных уравнений в частных производных, описывающая движение вязкой ньютоновской жидкости (1822 г.) - по имени французского физика Анри Навье и британского математика Джорджа Стокса.

В динамической метеорологии для описания движения воздушных масс атмосферы, в частности при формировании прогноза погоды. Решение – скорость и давление воздуха в точке (x,y,z).

Нет аналитического решения.

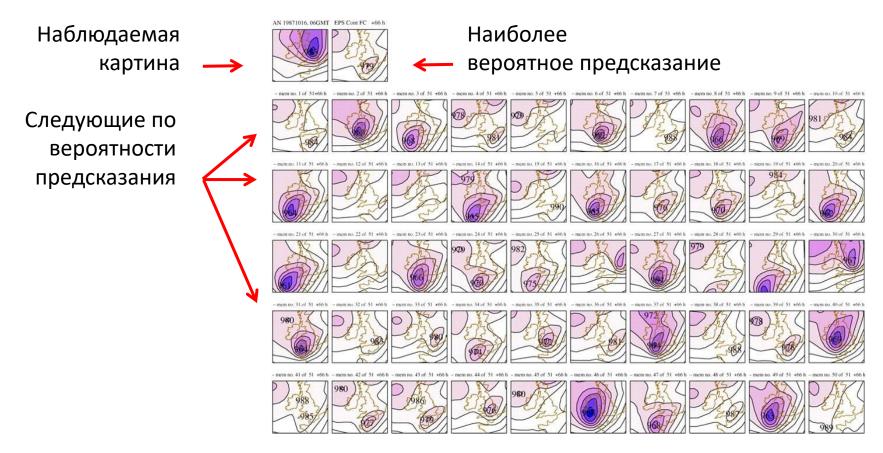


Приемлемая точность численного решения - только при расчётной сетке, ячейки которой меньше самого мелкого вихря.

Очень большие затраты расчётного времени на суперкомпьютерах.

Уравнения Навье-Стокса:

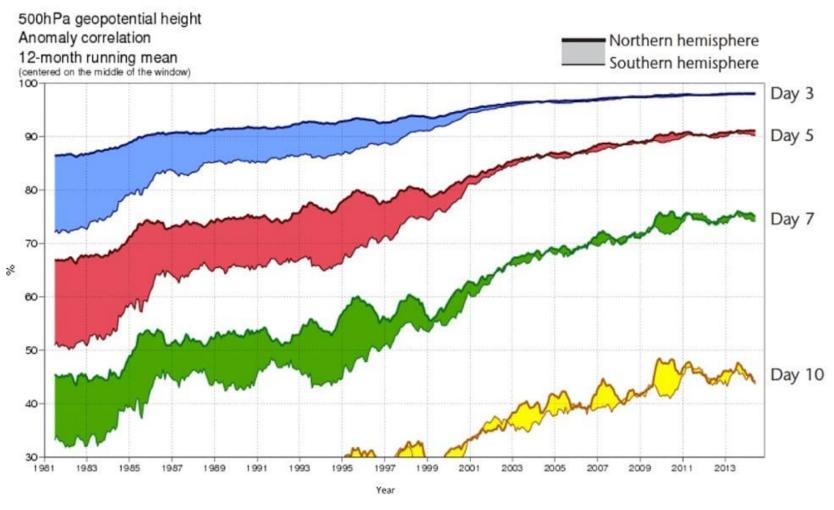
предсказание «великого шторма» 1987 г. за 66 часов



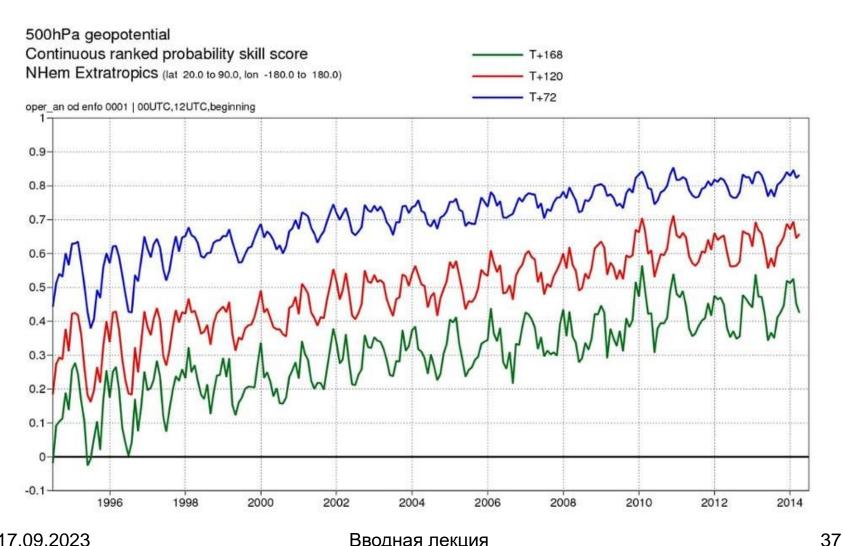
https://www.nanonewsnet.ru/news/2018/stavka-na-uluchshenie-predskazanii-novaya-matematika-prognozov-pogody

35

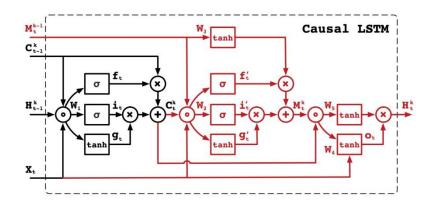
Качество прогноза погоды



Прогноз погоды от 1995 до 2014



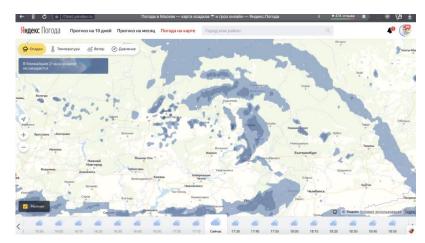
Нейросети для прогнозирования погоды



Архитектура рекуррентной ячейки Causal LSTM.

Красным цветом выделено отличие от классической ConvLSTM





Сравнение карты осадков без нейросетевой склейки (слева) и с ней (справа)

https://habr.com/ru/companies/yandex/articles/504794/

Какой эмоциональный окрас имеет текст?

Варианты: позитивный, нейтральный, негативный

Применение: автоматический анализ отзывов от пользователей

«Большое спасибо! Сюдя по всему, это как раз то, чего не хватает всем зарубежным курсам по Machine Learning и Knowledge Discovery. Это теория, математика, объяснение того, как оно устроено "в кишках".»

Какой окрас?

«Я вижу очень большой минус, что курс будет на готовой библиотеке sci-kit. Курс от Andrew лучше тем, что ученик сам пишет алгоритм и видит изнутри, как он работает.»

Какой окрас?

- *х* текст на русском языке
- f(x) его окрас, $f(x) \in \{-1, 0, 1\}$ Можно ли выписать формулу для f(x)?

Область определения — не числа. Область значений — числа. Точная аналитическая формула для зависимости может не существовать.

Примеры сложных задач

- Какой будет спрос на товар в следующем месяце?
- Сколько денег заработает магазин за год?
- Вернет ли клиент кредит? (кредитный скоринг)
- Заболеет ли пациент раком?
- Сдаст ли студент следующую сессию?
- На фотографии гуманитарий или технарь?
- Кто выиграет битву в онлайн-игре?

Особенности сложных задач

- Везде очень сложные неявные зависимости Нельзя выразить их формулой
- Но есть некоторое число примеров Тексты с известным окрасом
- Будем приближать зависимости, используя примеры

Машинное обучение — восстановление сложной зависимости по конечному числу примеров.

Концепция МО

- Решение задач путем обработки прошлого опыта (case-based reasoning)
- Альтернатива построению математических моделей (model-based reasoning)
- Основное требование наличие обучающей информации
- Как правило в качестве таковой выступает выборка прецедентов – ситуационных примеров из прошлого с известным исходом
- Требуется построить алгоритм, который позволял бы обобщить опыт прошлых наблюдений/ситуаций для обработки новых, не встречавшихся ранее случаев, исход которых неизвестен.

Основные термины

- объект (object)
- признаки (features)
- ответ, целевая переменная (target, ground truth)
- прогноз (output, prediction)
- прецедент (объект+истинный ответ)
- обучающая выборка (training sample)
- алгоритм, модель, решающая функция (decision function)
- целевая функция (target function)
- обучение алгоритма (learning)
- тестовая выборка (testing sample)
- функция потерь (loss function, cost function)
- функционал качества, функционал ошибки

Пример 1 задачи МО: определение местонахождения дома

Определить, находится ли здание в Сан-Франциско или в Нью-Йорке (задача классификации в МО).



A Visual Introduction to Machine Learning [Электронный ресурс] / Режим доступа: http://www.r2d3.us/visual-intro-to-machine-learning-part-1/, свободный (дата обращения 01.09.2023)

Пример 2 задачи МО: выбор точки размещения ресторана

- Есть сеть ресторанов по всему миру
- Хотим открыть еще один в Москве
- Несколько вариантов размещения
- Какой из вариантов принесет максимальную прибыль?

см. kaggle.com, TFI Restaurant Revenue Prediction

https://www.kaggle.com/code/user47/tfi-restaurant-revenue-prediction -

Обозначения

- x объект (для него будем делать прогноз)

 Название ресторана или ID в списке ресторанов
- у ответ, целевая переменная, target (что прогнозируем)
 Прибыль в течение первого года работы
- \mathbb{Y} пространство ответов (все возможные значения ответа) \mathbb{R} вещественные числа

Объекты / признаки

Объект х — абстрактная сущность (ресторан).

Признаки — характеристики объектов (числовые, категориальные, текстовые, изображения и т.д.), d — число признаков.

Компьютеры работают только с числами, поэтому всегда переводим всё в числовые характеристики, тогда признаки (features) объекта \mathbf{x} — числа $f_1(\mathbf{x})$, $f_2(\mathbf{x})$, ..., $f_d(\mathbf{x})$.

not:
$$x_j = f_j(x), j=1, ..., d$$

Далее вместо абстрактного объекта x работаем с его признаковым описанием $\mathbf{x} = (x_1, ..., x_d)$

Признаковое описание

Объект: х

Характеристики объекта х:

$$f_1(x), f_2(x), ..., f_d(x)$$

Сокращенное обозначение характеристик:

$$x_1, \ldots, x_d$$

Признаковое описание объекта х:

$$\mathbf{x} = (x_1, \ldots, x_d)$$

Признаковое описание

Объект: х

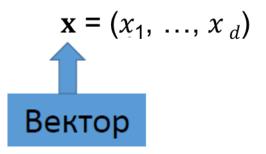
Характеристики объекта х:

$$f_1(x), f_2(x), ..., f_d(x)$$

Сокращенное обозначение характеристик:

$$x_1, \ldots, x_d$$

Признаковое описание объекта х:



Признаковое описание

Объект: х

Характеристики объекта х:

$$f_1(x), f_2(x), ..., f_d(x)$$

Сокращенное обозначение характеристик:

$$x_1, \ldots, x_d$$

Признаковое описание объекта х :

$$\mathbf{x} = (x_1, ..., x_d)$$
 Числа

Признаки (Что влияет на прибыль ресторана?)

Демография:

- средний возраст жителей ближайших кварталов
- динамика числа жителей

Недвижимость:

- средняя стоимость квадратного метра жилья поблизости
- число школ, банков, магазинов, заправок
- расстояние до ближайшего конкурента

Дорожный трафик:

• среднее число машин, проезжающих мимо за день

Обучающая выборка

Мы ничего не понимаем в экономике. Зато имеем много объектов \mathbf{x}_i с известными значениями y_i целевой переменной, $i=1,2,...,\ell$.

 $X^{\ell} = (\mathbf{x}_i, y_i)_{i=1}^{\ell}$ - выборка (обучающая, тестовая) ℓ - размер выборки $y(\mathbf{x})$ - целевая функция (target function), неизвестная зависимость y_i - целевая переменная (target variable), известный истинный ответ для объекта \mathbf{x}_i

Хотим найти *целевую* функцию $y(\mathbf{x})$: $y(\mathbf{x}_i) = y_i \ \forall i = 1, ..., \ell$. Вместо этого находим *решающую* функцию $a(\mathbf{x})$.

Объекты-признаки

 $X^{\ell} = (\mathbf{x}_i, y_i)_{i=1}^{\ell}$ - выборка (обучающая, тестовая) ℓ - размер выборки (число прецедентов) d - длина признакового описания (число признаков объекта)

 (\mathbf{x}_i, y_i) - i-й прецедент выборки X^ℓ , $i = 1, 2, ..., \ell$

$$\mathbf{x}_i = egin{pmatrix} x_{i1} \\ \dots \\ x_{id} \end{pmatrix}$$
 - i -й объект выборки X^ℓ , $i=1,2,\dots,\ell$

 x_{ij} - j-й признак i-го объекта выборки X^ℓ , j=1,2,..., d

Матрица «объекты-признаки»

Матрица «объекты—признаки» (feature data) — совокупность признаковых описаний всех объектов выборки $X^{\ell}=(\mathbf{x}_i,y_i)_{i=1}^{\ell}$, записанная в виде таблицы размера $\ell \times d$. Для $i=1,2,...,\ell=9$ и j=1,2,...,d=4 матрица «объекты—признаки» имеет вид

$$\mathbf{F} = ||f_j(\mathbf{x}_i)||_{9 \times 4} = \begin{pmatrix} f_1(\mathbf{x}_1) \dots f_4(\mathbf{x}_1) \\ \dots & \dots \\ f_1(\mathbf{x}_9) \dots f_4(\mathbf{x}_9) \end{pmatrix} = \begin{pmatrix} x_{11} \dots x_{1d} \\ \dots & \dots \\ x_{\ell 1} \dots x_{\ell d} \end{pmatrix}$$

Алгоритм

 $a(\mathbf{x})$ — модель, алгоритм, решающая функция (decision function) $a(\mathbf{x}): \mathbb{X} \to \mathbb{Y}$, отображающая \mathbb{X} в \mathbb{Y} и предсказывающая ответ для любого объекта

Линейная модель:

$$a(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_d x_d$$
 (1)

Например:

 $a(\mathbf{x}, \mathbf{w}) = 1\ 000\ 000 + 100\ 000 * (расстояние до конкурента) – 100\ 000 * (расстояние до метро)$

Задача обучения с учителем (обучение по прецедентам)

По обучающей выборке X^{ℓ} построить *модель* (алгоритм) $a: \mathbb{X} \to \mathbb{Y}$, которая приближала бы целевую функцию $y(\mathbf{x})$, не только на объектах обучающей выборки, но и на всём множестве \mathbb{X} .

Функция потерь

Не все алгоритмы полезны, напр.,

- $a(\mathbf{x}) = 0$ не принесет никакой выгоды;
- $a(\mathbf{x})$ = средняя прибыль по всем рассмотренным точкам расположения

Функция потерь (loss function) — мера корректности ответа алгоритма, напр., квадратичная ошибка:

$$\mathcal{L}(a, y_i) = (a(\mathbf{x}_i, \mathbf{w}) - y_i)^2$$
 (2)

Предсказали 100 000 руб. прибыли, а на самом деле 50 000 руб. — хорошо или плохо работает алгоритм?

Функционал качества

Функционал качества $Q(a, X^{\ell})$, функционал ошибки (cost function) — мера качества работы алгоритма $a(\mathbf{x}, \mathbf{w})$ на выборке X^{ℓ} .

Суммарная квадратичная ошибка:

$$\sum_{i=1}^{\ell} \mathcal{L}(a, y_i) = \sum_{i=1}^{\ell} (a(\mathbf{x}_i, \mathbf{w}) - y_i)^2 \longrightarrow \min_{\mathbf{w}}$$
 (3)

Среднеквадратичная ошибка (Mean Squared Error, MSE):

$$Q(a, X^{\ell}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(a, y_i) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(\mathbf{x}_i, \mathbf{w}) - y_i)^2 \longrightarrow \min_{\mathbf{w}} \quad (4)$$

Функционал ошибки

- должен соответствовать бизнес-требованиям
- одно из важнейших составляющих анализа данных

Обучение алгоритма

Дано:

- обучающая выборка $X^{\ell} = (\mathbf{x}_i, y_i)_{i=1}^{\ell}$
- выражение для функционала ошибки $Q(a, X^\ell)$
- семейство алгоритмов \mathcal{A} (из него выбираем алгоритм), напр., все линейные модели $\mathcal{A} = \{ w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_d x_d, \ w_0, w_1, \ldots, w_d \in \mathbb{R} \}$

Найти:

оптимальный алгоритм, т.е. найти $\mathbf{w} = (w_0, w_1, ..., w_d)$

Обучение - поиск алгоритма $a^*(\mathbf{x}, \mathbf{w})$, оптимального с точки зрения функционала ошибки (1):

$$a^*(\mathbf{x}, \mathbf{w}) = \arg\min_{a \in \mathcal{A}} Q(a, X^{\ell})$$
 (5)

$$a(x) = \arg\min_{a \in \mathcal{A}} Q(a, X)$$

Типы задач в машинном обучении

- 1. Обучение с учителем (supervised learning)
 - регрессия
 - классификация (бинарная, многоклассовая, с пересекающимися классами)
 - ранжирование
 - частичное обучение
- 2. Обучение без учителя (unsupervised learning)
 - кластеризация
 - поиск аномалий
 - оценивание плотности
- 3. Обучение с подкреплением (reinforcement learning)

и т.д.

Этапы решения задачи в обучении с учителем

1. Этап обучения алгоритма

построение оптимального алгоритма по выборке

2. Этап применения алгоритма

Применение алгоритма к новым объектам

Методология решения задачи МО

- 1. Постановка задачи.
- 2. Выделение признаков.
- 3. Формирование выборки (обучение (валидация) тест).
- 4. Выбор функционала ошибки.
- 5. Предобработка данных (выделение и масштабирование признаков, выбор признаков, понижение размерности, построение гистограммы распределения значений целевой переменной, использование др. способов графического представления данных).
- 6. Построение модели (обучение).
- 7. Оценивание качества модели.